

Estimacion de la Curva de Rendimientos de Suecia Utilizando el Modelo Nelson-siegel Dinámico

Leonel Espinoza
Universidad Nacional Autónoma de Honduras
e-mail: leonel.Espinoza@unah.edu.hn

ÍNDICE

I.	Introducción	2
II.	Defnición del Problema	2
III.	Preliminares y Notación	2
IV.	Estimaciones de Modelo Nelson Sigel Dinamico	3
V.	Resultados	3
V-A.	Primer resultado	3
V-B.	Segundo resultado	3
V-C.	curvas de rendimiento	4
VI.	Modelo VAR (Modelos Vectoriales Autorregresivos)	5
VII.	Estimación Modelo VAR	5
VIII.	Validación del Modelo VAR	5
IX.	Estacionariedad y Cointegración	5
X.	Ajuste modelo VAR	6
X-A.	La prueba ARCH (Autoregressive Conditional Heteroscedasticity)	6
XI.	Anexos	6
XI-A.	Prueba de Estacionaridad Dickey-Fuller	6
XI-B.	Prueba de cointegracion Johansen-Procedure	7
XII.	Modelo DCC-GARCH	7
XII-A.	Media (AR(p) para cada $\beta_{i,t}$):	7
XII-B.	Varianzas condicionales univariadas (GARCH(1,1)):	7
XIII.	Predicciones del Modelo DCC-GARCH	7
XIV.	Ajuste modelo DCC-GARCH	7
XV.	Trabajo Futuro	9
	Referencias	9

ÍNDICE DE FIGURAS

1.	Enter Caption	3
2.		4
3.		4
4.		5
5.		6
6.		6
7.	Enter Caption	7
8.		8

9.		8
10.		8
11.		8

ÍNDICE DE CUADROS

I.	Valores BetasDNS	3
II.	Cuadro II: VALORES YESTIMADODNS	4
III.	Errores por período	4
IV.	Resultados del test ARCH multivariante para los residuales del modelo VAR	6
V.	Cuadro II: VALORES REALES	6
VI.	Cuadro II: VALORES ESTIMADOS	6
VII.	Resultados de las pruebas Dickey-Fuller	7
VIII.	Resultados del test de cointegración	7
IX.	Test de cointegración	7
X.	Resultados del Test ARCH para heterocedasticidad	8
XI.	Resultados del Test Ljung-Box para autocorrelación	8
XII.	Cuadro II: VALORES REALES	8
XIII.	Cuadro II: VALORES ESTIMADOS	8

Estimacion de la Curva de Rendimientos de Suecia Utilizando el Modelo Nelson-siegel Dinámico

Resumen—El modelo Nelson-Siegel es un modelo factorial de la curva de rendimiento. Este modelo se basa en la idea de que la curva de rendimiento puede descomponerse en varios componentes, cada uno de los cuales describe un aspecto diferente de su comportamiento.

El modelo Nelson-Siegel utiliza esencialmente tres parámetros de suavizado para describir la forma de la curva de rendimiento. El primer parámetro β_0 , describe el nivel a largo plazo de las tasas de interés. El segundo parámetro β_1 , describe la pendiente, mientras que el tercer parámetro β_2 , Describe la curvatura de la curva de rendimiento.

Estos parámetros se utilizan para generar una representación matemática de la curva de rendimiento que permite predecir las fluctuaciones futuras de los tipos de interés.

El modelo dinámico de Nelson-Siegel (DNS) es una extensión del modelo estático, en la cual los factores cambian en el tiempo, lo que permite analizar la evolución temporal de la curva de rendimientos.

El modelo Nelson-Siegel es una herramienta poderosa para comprender y predecir la dinámica de las tasas de interés. Su capacidad para descomponer la curva de rendimiento en sus componentes subyacentes lo convierte en una herramienta muy útil para operadores de bonos y gestores de cartera

I. INTRODUCCIÓN

La estructura temporal de la curva de rendimiento, se puede ver como un elemento esencial que nos permitirá llevar a cabo el análisis a nivel macroeconómico y financiero, se dice que esta curva con la que se explica la relación que hay entre los rendimientos que obtienen los activos respecto a los plazos de vencimiento de los activos constituye un indicador que ofrece información política monetaria y sobre la situación económica vigentes en un país.

En el caso del mercado de deuda a largo plazo de Suecia, la curva de rendimiento se construye a partir de dos instrumentos emitidos por la Oficina Nacional de Deuda: las letras del tesoro (instrumentos de deuda a corto plazo y cupón cero, con vencimiento no mayor de un año) y los bonos del estado (la deuda a largo plazo mediante cupones periódicos). La convergencia de estos dos instrumentos que presentan distintas características de pago hace difícil obtener una curva de rendimiento consistente para toda la extensión de plazos.

La problemática que se enfoca en esta investigación radica exactamente en el tratamiento del modelo Nelson-Siegel Dinámico para la curva de rendimiento sueca y para los rendimientos mensuales de sus Letras del Tesoro y Bonos del Estado, aplicando una serie de datos históricos de rendimientos (que van de enero de 1996 hasta diciembre de 2011 y que recogen siete vencimientos clave (1, 3 y 6 meses; 2, 5, 7 y 10 años). A través de este estudio queremos:

1. Estimar la curva de rendimiento sueca, ajustando de modo que derive a una curva suave y continua que se ajusta a los datos observados para los distintos instrumentos
2. Modelar la dinámica temporal de los tres factores latentes del modelo (el nivel, la pendiente y la curvatura) para comprender su comportamiento a través del ciclo económico.
3. Hacer predicciones sobre los futuros rendimientos de estos activos de deuda evaluando la capacidad predictiva del modelo DNS,

II. DEFINICIÓN DEL PROBLEMA

El problema central de estudio es: estimar la curva de rendimiento y de los rendimientos mensuales de las letras del Tesoro sueco y de los bonos del Estado, a través del modelo Nelson-Siegel Dinámico y se harán predicción de estas letras y bonos.

Las letras del Tesoro son instrumentos de deuda a corto plazo con vencimientos inferiores a un año en Suecia, las letras del Tesoro tienen cuatro plazos: un mes, tres meses, seis meses y un año.

Las letras del tesoro son Cupón cero: No pagan intereses periódicos.

Los bonos del Estado sueco son instrumentos de deuda a largo plazo con cuatro vencimientos: dos años, cinco años, siete años y diez años, las letras del Tesoro y los bonos del Estado son emitidos por la Oficina Nacional de Deuda de Suecia.

Los Bonos del Gobierno Pagan cupones periódicos: Intereses regulares

Los datos finales corresponden a los rendimientos de los bonos cupón cero desde enero de 1996 hasta diciembre de 2011 y a siete vencimientos: un mes, tres meses, seis meses, dos años, cinco años, siete años y diez años.

III. PRELIMINARES Y NOTACIÓN

El modelo propuesto por Nelson-Siegel (1987).

$$y(\tau) = \beta_0 + \beta_1 \left(\frac{1 - e^{-\lambda\tau}}{\lambda\tau} \right) + \beta_2 \left(\frac{1 - e^{-\lambda\tau}}{\lambda\tau} - e^{-\lambda\tau} \right) \quad (1)$$

Donde:

- $y_t(\tau)$: Es el rendimiento al vencimiento τ en el tiempo t .
- τ : Es el plazo (o tiempo) hasta el vencimiento.
- $\beta_{0t}, \beta_{1t}, \beta_{2t}$: Son los tres coeficientes latentes (o factores) de la curva en el tiempo t .

- $\lambda_t > 0$: Es un parámetro de suavizado que controla la decaída exponencial de los factores.

La ecuación de medición L para dos modelos DNS es:

$$\begin{bmatrix} y_t(\tau_1) \\ y_t(\tau_2) \\ \vdots \\ y_t(\tau_N) \end{bmatrix} = \begin{bmatrix} 1 & \frac{1 - e^{-\lambda\tau_1}}{\lambda\tau_1} & \frac{1 - e^{-\lambda\tau_1}}{\lambda\tau_1} - e^{-\lambda\tau_1} \\ 1 & \frac{1 - e^{-\lambda\tau_2}}{\lambda\tau_2} & \frac{1 - e^{-\lambda\tau_2}}{\lambda\tau_2} - e^{-\lambda\tau_2} \\ \vdots & \vdots & \vdots \\ 1 & \frac{1 - e^{-\lambda\tau_N}}{\lambda\tau_N} & \frac{1 - e^{-\lambda\tau_N}}{\lambda\tau_N} - e^{-\lambda\tau_N} \end{bmatrix} \begin{bmatrix} L_t \\ S_t \\ C_t \end{bmatrix} + \begin{bmatrix} \varepsilon_t(\tau_1) \\ \varepsilon_t(\tau_2) \\ \vdots \\ \varepsilon_t(\tau_N) \end{bmatrix} \quad (2)$$

IV. ESTIMACIONES DE MODELO NELSON SIGEL DINAMICO

estimaremos por minimos cuadrados nuestros parametros y usaremos la formula

$$\hat{\beta} = (\mathbf{L}^\top \mathbf{L})^{-1} \mathbf{L}^\top \mathbf{Y}^\top \quad (3)$$

ahora nuestra curva estimada sera de la forma

$$\hat{\mathbf{Y}} = (\mathbf{L}\hat{\beta})^\top \quad (4)$$

El estimador OLS para los factores β_t es

$$\hat{\beta}_t(\lambda) = (\mathbf{L}(\tau, \lambda)^\top \mathbf{L}(\tau, \lambda))^{-1} \mathbf{L}(\tau, \lambda)^\top \mathbf{Y}_t.$$

Las curvas estimadas para cada t son:

$$\hat{y}_t(\lambda) = L(\tau, \lambda) \hat{\beta}_t(\lambda).$$

La suma total de errores cuadrados (SSE) para todo el conjunto es

$$\text{SSE}(\lambda) = \sum_{t=1}^T \|y_t - \hat{y}_t(\lambda)\|^2$$

En notación matricial, si $\hat{\mathbf{Y}}(\lambda) = \hat{\mathbf{B}}(\lambda) \mathbf{L}(\tau, \lambda)^\top$ entonces

$$\text{SSE}(\lambda) = \sum_{i,j} (Y_{ij} - \hat{Y}_{ij}(\lambda))^2.$$

El valor óptimo de λ que se obtiene por búsqueda es

$$\hat{\lambda} = \arg \min_{\lambda \in \Lambda} \text{SSE}(\lambda),$$

donde Λ denota el conjunto de valores considerados en la malla.

V. RESULTADOS

los resultados preliminares son:

V-A. Primer resultado

al resolver por minimos cuadrados los valores de nuestros betas seran:

Cuadro I
VALORES BETASDNS

t	$\hat{\beta}_{0,t}$	$\hat{\beta}_{1,t}$	$\hat{\beta}_{2,t}$
1	8.807682	-0.821487103	-3.15748345
2	9.484643	-2.021684052	-3.26254509
3	9.321966	-2.509590634	-2.99705674
4	8.789298	-2.682297070	-2.07879385
5	9.167281	-3.071743521	-2.67159112
6	8.875911	-3.282067331	-2.48242721
7	9.027605	-3.810739565	-1.73359889
8	8.845900	-4.002211900	-1.98505875
9	8.059363	-3.423267638	-2.10922110
10	8.292806	-3.788906161	-3.34306116
11	7.832734	-3.649228222	-3.59676115
12	7.578740	-3.897098514	-3.88598331
13	7.736757	-3.741798694	-4.29887491
14	7.680202	-3.522433646	-4.37850195
15	8.277796	-4.260343093	-4.22791861
16	8.188650	-4.086870107	-3.87508011
17	7.897585	-3.812939275	-3.34495682
18	7.420788	-3.325346865	-3.52224674
19	6.989199	-2.836827222	-2.51462941
20	7.237602	-3.162220074	-2.39870985
21	6.632731	-2.491673469	-2.05047272
22	6.787987	-2.622036853	-1.11994324
23	6.562149	-2.229848308	-0.56823789
24	6.238443	-1.848909746	-0.68781782
25	5.805725	-1.571405267	-0.11428285
26	5.673311	-1.222505569	-0.59317567
27	5.357520	-0.945552102	0.11024903
28	5.514769	-1.026483052	-0.35382992
29	5.287071	-0.977235693	-0.83622451
30	5.296443	-1.110886175	-1.46261495
31	5.194820	-1.006394552	-1.28701743
32	5.043614	-0.814095957	-0.86876896
33	4.945377	-0.688613911	-1.04908804
34	4.933182	-0.930905275	-1.51088767




Figura 1. Enter Caption

V-B. Segundo resultado

usando la formula nuestras nuevas observaciones sera

Cuadro II
CUADRO II: VALORES YESTIMADODNS

t	$\hat{M}1$	$\hat{M}3$	$\hat{M}6$	$\hat{Y}^2$	$\hat{Y}^5$	$\hat{Y}^7$	$\hat{Y}^{10}$
1	7.9158	7.7950	7.6567	7.4530	7.8546	8.0789	8.2860
2	7.4266	7.3701	7.3196	7.4821	8.1982	8.5122	8.7913
3	6.7992	6.7853	6.7903	7.1470	7.9723	8.3066	8.5993
4	6.1271	6.1725	6.2499	6.7967	7.6109	7.9089	8.1642
5	6.1097	6.1459	6.2161	6.7995	7.7495	8.1061	8.4133
6	5.6202	5.6788	5.7778	6.4559	7.4484	7.8098	8.1190
7	5.2824	5.4118	5.6006	6.5569	7.6400	7.9990	8.2993
8	4.9072	5.0343	5.2220	6.2023	7.3496	7.7354	8.0592
9	4.6782	4.7649	4.8991	5.6769	6.6832	7.0348	7.3328
10	4.5199	4.5600	4.6460	5.3581	6.5327	6.9751	7.3565
11	4.1875	4.2079	4.2642	4.8949	6.0490	6.4950	6.8816
12	3.6845	3.7039	3.7611	4.4281	5.6633	6.1419	6.5571
13	3.9805	3.9688	3.9872	4.5440	5.7643	6.2538	6.6815
14	4.1340	4.1033	4.1013	4.5767	5.7455	6.2238	6.6433
15	4.0215	4.0439	4.1081	4.8410	6.1898	6.7117	7.1643
16	4.1109	4.1409	4.2148	4.9437	6.2270	6.7183	7.1435
17	4.1013	4.1447	4.2301	4.9500	6.1309	6.5751	6.9579
18	4.0916	4.0972	4.1327	4.6714	5.7379	6.1572	6.5220
19	4.1640	4.1949	4.2567	4.7885	5.6687	6.0005	6.2867
20	4.1006	4.1567	4.2516	4.9039	5.8606	6.2092	6.5075
21	4.1561	4.1917	4.2616	4.7465	5.5100	5.7932	6.0364
22	4.2133	4.3002	4.4408	5.1095	5.8503	6.0935	6.2964
23	4.3842	4.4837	4.6229	5.2482	5.8550	6.0415	6.1944
24	4.4260	4.4969	4.5984	5.0850	5.6012	5.7673	5.9052
25	4.2796	4.3650	4.4815	4.9643	5.3746	5.4910	5.5841
26	4.4707	4.5123	4.5684	4.8698	5.2195	5.3366	5.4348
27	4.4446	4.5056	4.5872	4.9041	5.1402	5.2007	5.2476
28	4.5094	4.5503	4.6084	4.8827	5.1676	5.2583	5.3334
29	4.3147	4.3270	4.3502	4.5378	4.8392	4.9520	5.0490
30	4.1756	4.1622	4.1557	4.2935	4.6671	4.8222	4.9587
31	4.1806	4.1704	4.1670	4.2975	4.6336	4.7721	4.8939
32	4.2284	4.2294	4.2377	4.3686	4.6301	4.7331	4.8227
33	4.2463	4.2303	4.2171	4.2816	4.5218	4.6255	4.7174
34	3.9853	3.9588	3.9350	4.0085	4.3388	4.4838	4.6128

Curvas de Rendimiento suavizada (1996-2011)




Figura 3.

Cuadro III
ERRORES POR PERÍODO

	Errores						
	EM1	EM3	EM6	EA2	EA5	EA7	EA10
1	0.0558	0.0050	0.0733	0.0030	0.0546	0.0089	0.0440
2	0.0134	0.0101	0.0196	0.0479	0.0582	0.0122	0.0387
3	0.1808	0.0753	0.1903	0.1030	0.0077	0.0034	0.0293
4	0.0929	0.0423	0.1099	0.1133	0.0809	0.0189	0.0458
5	0.0003	0.0541	0.0861	0.0705	0.0695	0.0061	0.0367
6	0.0798	0.0688	0.0478	0.0741	0.0684	0.0102	0.0210
7	0.0776	0.0218	0.1106	0.1031	0.0800	0.0010	0.0307
8	0.1028	0.0143	0.1620	0.1277	0.0796	0.0054	0.0308
9	0.0918	0.0051	0.1691	0.1231	0.0732	0.0048	0.0272
10	0.0399	0.0680	0.0556	0.1019	0.1227	0.0751	0.1235
11	0.0925	0.0679	0.0842	0.1351	0.1090	0.0650	0.0984
12	0.0255	0.0639	0.0089	0.1219	0.1533	0.0919	0.1529
13	0.1205	0.0312	0.1128	0.0660	0.1743	0.1038	0.1885
14	0.0441	0.0053	0.0686	0.0067	0.0545	0.2038	0.1367
15	0.0113	0.0039	0.0219	0.0110	0.1002	0.2017	0.1058
16	0.0309	0.0219	0.0752	0.0237	0.0730	0.1783	0.1065
17	0.0513	0.0053	0.0699	0.0200	0.0491	0.1551	0.1021
18	0.0084	0.0172	0.0027	0.0386	0.0221	0.1672	0.1180
19	0.0240	0.0051	0.0233	0.0115	0.0213	0.1305	0.0933
20	0.0706	0.0133	0.0884	0.0239	0.0294	0.1392	0.1025
21	0.0261	0.0183	0.0038	0.0335	0.0000	0.1432	0.1136
22	0.0633	0.0138	0.0792	0.0295	0.0297	0.1035	0.0736
23	0.0342	0.0437	0.1171	0.0582	0.0550	0.0715	0.0356
24	0.0860	0.0231	0.1016	0.0350	0.0088	0.0873	0.0748
25	0.0996	0.0350	0.0985	0.0043	0.0846	0.0110	0.0659
26	0.0107	0.0202	0.0316	0.0302	0.0595	0.0266	0.0552
27	0.0446	0.0044	0.0528	0.0159	0.0502	0.0507	0.0724
28	0.0006	0.0003	0.0084	0.0273	0.0176	0.0483	0.0466
29	0.0347	0.0230	0.0198	0.0022	0.0092	0.0420	0.0410
30	0.0156	0.0078	0.0143	0.0085	0.0179	0.0372	0.0213
31	0.0006	0.0004	0.0030	0.0075	0.0264	0.0321	0.0112
32	0.0284	0.0206	0.0223	0.0286	0.0299	0.0131	0.0027
33	0.0063	0.0097	0.0071	0.0134	0.0032	0.0505	0.0376
34	0.0353	0.0312	0.0050	0.0215	0.0258	0.0588	0.0622

V-C. curvas de rendimiento




Figura 2.




Figura 4.

VI. MODELO VAR (MODELOS VECTORIALES AUTORREGRESIVOS)

Utilizamos un modelo del tipo vector autoregresivo (VAR) cuando queremos caracterizar las interacciones simultáneas entre un grupo de variable. Un VAR es un modelo de ecuaciones simultáneas formado por un sistema de ecuaciones de forma reducida sin restringir. Que sean ecuaciones de forma reducida quiere decir que los valores contemporáneos de las variables del modelo no aparecen como variables explicativas en ninguna de las ecuaciones el modelo tiene la forma:

$$\beta_t = A_0 + \sum_{s=1}^p A_s \beta_{t-s} + u_t \quad (5)$$

donde:

- $P \rightarrow$ es el orden de rezagos del modelo, es decir, el número de períodos anteriores (rezagos) de las variables que se incluyen en las ecuaciones del modelo VAR para explicar las variables actuales.
- $\beta_t \rightarrow$ es un vector de factores dinámicos (nivel, pendiente, curvatura).
- $A_s \rightarrow$ matrices que describen cómo los factores pasados influyen en los actuales.
- $u_t \rightarrow$ Vector de errores.

VII. ESTIMACIÓN MODELO VAR

Utilizaremos los betas estimados anteriormente para ajustar este modelo y luego hacer predicciones de estos betas y con eso haremos nuestras predicciones de las curvas de rendimiento el modelo VAR también puede escribirse como:

$$Y = ZB + U \quad (6)$$

Estimaremos por mínimos cuadrados ordinarios y su fórmula será:

$$\hat{B} = (Z'Z)^{-1} Z'Y$$

donde:

$$B = \begin{bmatrix} \hat{A}'_0 \\ \hat{A}'_1 \\ \hat{A}'_2 \\ \vdots \\ \hat{A}'_p \end{bmatrix} \quad Z = \begin{bmatrix} 1 \\ \beta_t \\ \beta_{t-1} \\ \vdots \\ \beta_{t-p+1} \end{bmatrix} \quad Y = \begin{bmatrix} \beta'_{p+1} \\ \beta'_{p+2} \\ \vdots \\ \beta'_n \end{bmatrix}$$

ahora nuestra predicción tendrá la forma

$$\hat{\beta}_{t+h|t} = \hat{A}_0 + \sum_{s=1}^p \hat{A}_s \hat{\beta}_{t+h-s|t} \quad (7)$$

En este modelo es importante elegir un valor de P el valor de P óptimo que utilizamos es el que minimiza el AIC que es el Criterio de Información de Akaike, que es el que mide el equilibrio entre el ajuste y la complejidad del modelo, su fórmula es:

$$AIC(p) = \ln \left| \det \hat{\Sigma}_u(p) \right| + \frac{2}{T} \times \left(\frac{Tk + pk}{2} \right) \quad (8)$$

donde:

- $\hat{\Sigma}_u(p)$: es la matriz de covarianza de los residuos del modelo VAR(p),
- $|\hat{\Sigma}_u(p)|$: es su determinante,
- k : es el número de variables endógenas del VAR,
- p : el número de rezagos (lags),
- T : número de observaciones efectivas (tras eliminar las p iniciales).

VIII. VALIDACIÓN DEL MODELO VAR

El modelo VAR asume un conjunto de supuestos estadísticos que permiten representarlo como una buena aproximación al proceso generador de datos los supuestos son:

- $U_t \sim N[0, \Sigma_u]$ Normal
- $\text{Var}(U_t) = \Sigma_u$ Constante
- $\text{Cov}(U_t, U_{t-i}) = 0$ para $i = 1, 2, \dots$ No existe autocorrelación
- Parámetros lineales y constantes en el tiempo

IX. ESTACIONARIEDAD Y COINTEGRACIÓN

La **estacionariedad** en la constitución de un modelo VAR quiere decir que las propiedades estadísticas del sistema de series temporales (de tipo media, varianza, autocovarianza) son constantes en el tiempo; es decir, que las series no tienen tendencias ni varianzas que cambian con el tiempo, dado que esto es importante ya que un modelo VAR necesita que las series temporales sean estacionarias para que las conclusiones sean válidas y se eviten resultados espurios y falsos. Para comprobar la estacionariedad entre las variables del VAR se aplican diversas pruebas estadísticas de raíz unitaria, como por ejemplo, la prueba de Dickey-Fuller aumentada (ADF), que determinan si una serie es o no una raíz unitaria (es o no es estacionaria).

La noción de **cointegración**, en el ámbito de un modelo VAR, remite a la existencia de una relación de equilibrio de larga duración entre dos o más variables no estacionarias. Si bien las series individualmente pudieran presentar cierta tendencia y no ser estacionarias, es posible que una combinación lineal de las mismas que sea estacionaria puese evidenciar que las series se mueven de una manera tal que mantienen, a través del tiempo, una relación estructural de manera moderada. Para identificar la cointegración se usan pruebas como la de Johansen, que buscan vectores de cointegración que representen estas relaciones de equilibrio.

X. AJUSTE MODELO VAR

Ajustaremos el modelo con nuestros coeficientes estimados anteriormente. nuestros residuos son:




Figura 5.

X-A. La prueba ARCH (Autoregressive Conditional Heteroscedasticity)

se usa esta prueba para el supuesto de Homoscedasticidad

Test ARCH Multivariante	
Datos:	Residuos del Modelo VAR
Chi-cuadrado:	261.86
Grados de libertad:	180
Valor p:	6.493e-05

Cuadro IV

RESULTADOS DEL TEST ARCH MULTIVARIANTE PARA LOS RESIDUALES DEL MODELO VAR

Prueba de hipótesis:

- **Hipótesis nula (H_0):** No hay efectos ARCH en los residuales (los residuos son homocedásticos)
- **Hipótesis alternativa (H_1):** Existen efectos ARCH en los residuales (los residuos son heterocedásticos)

Empezaremos prediciendo 14 periodos hacia adelante, en este caso nuestra data esta dividida mensualmente entonces estimaremos las tasas los siguientes 14 meses desde el ultimo mes de nuestra data que es noviembre 2011 que son:

Cuadro V
CUADRO II: VALORES REALES

t	M1	M3	M6	Y2	Y5	Y7	Y10
1	1.7000	1.4000	1.3500	0.8400	1.2200	1.2200	1.6200
2	1.8000	1.6500	1.5000	0.8950	1.2900	1.4700	1.7100
3	1.6500	1.5500	1.5000	1.0300	1.4400	1.6300	1.9000
4	1.5500	1.4700	1.4700	1.2800	1.6000	1.7600	1.9800
5	1.5500	1.4500	1.4000	1.1500	1.4100	1.5600	1.7900
6	1.5000	1.3200	1.3500	0.7700	0.9770	1.0800	1.2800
7	1.3000	1.1000	1.1000	0.9920	1.2300	1.3500	1.6000
8	1.4500	1.1000	1.1000	0.9700	1.0600	1.1600	1.3800
9	1.5000	1.1500	1.1200	0.8540	1.0100	1.1500	1.4100
10	1.1200	1.0000	0.9500	0.6750	0.9680	1.1400	1.4700
11	1.2500	1.1000	1.0300	0.7630	1.0100	1.1900	1.5300
12	1.2300	1.0700	0.9500	0.7140	0.9580	1.1500	1.4700
13	1.0500	0.9800	0.8900	0.7380	0.9680	1.2000	1.5300
14	1.0500	0.9400	0.8800	1.0200	1.3800	1.6200	1.9800

Ahora después de estimar nuestros beta nuestras predicciones serán:

Cuadro VI
CUADRO II: VALORES ESTIMADOS

t	$\hat{M}1$	$\hat{M}3$	$\hat{M}6$	$\hat{Y}^2$	$\hat{Y}^5$	$\hat{Y}^7$	$\hat{Y}^{10}$
1	1.4950	1.3034	1.0787	0.6564	1.0893	1.3641	1.6221
2	1.3415	1.1835	1.0030	0.7418	1.2775	1.5748	1.8493
3	1.1209	1.0030	0.8723	0.7515	1.3035	1.5857	1.8430
4	0.9922	0.9098	0.8246	0.8503	1.4614	1.7479	2.0056
5	0.9001	0.8511	0.8082	0.9667	1.6239	1.9106	2.1651
6	0.8477	0.8255	0.8165	1.0779	1.7639	2.0476	2.2969
7	0.8319	0.8339	0.8554	1.2050	1.9077	2.1848	2.4261
8	0.8473	0.8684	0.9136	1.3296	2.0388	2.3082	2.5409
9	0.8846	0.9204	0.9834	1.4452	2.1490	2.4084	2.6310
10	0.9376	0.9842	1.0602	1.5518	2.2434	2.4922	2.7044
11	1.0011	1.0550	1.1396	1.6469	2.3214	2.5594	2.7615
12	1.0693	1.1276	1.2171	1.7290	2.3830	2.6105	2.8030
13	1.1390	1.1994	1.2911	1.7996	2.4320	2.6498	2.8337
14	1.2072	1.2681	1.3597	1.8592	2.4702	2.6793	2.8556




Figura 6.

XI. ANEXOS

En estas sección presentaremos todas los test realizados en nuestro estudio.

XI-A. Prueba de Estacionaridad Dickey-Fuller

se le aplico la prueba de estacionaridad a nuestras tres series de tiempo que usaremos para ajustar el modelo VAR los resultados fueron

Cuadro VII
RESULTADOS DE LAS PRUEBAS DICKEY-FULLER

	Serie B0	Serie B1	Serie B2
Estadístico Dickey-Fuller	-3.7503	-3.8869	-2.7897
p-value	0.02281	0.01607	0.2457

Donde nuestra hipótesis alternativa es que la serie es estacionaria.

XI-B. Prueba de cointegración Johansen-Procedure

Cuadro VIII
RESULTADOS DEL TEST DE COINTEGRACIÓN

Test	10pct	5pct	1pct	Valor Crítico
$r \leq 2$	7.75	7.52	9.24	12.97
$r \leq 1$	21.51	17.85	19.96	24.60
$r = 0$	61.32	32.00	34.91	41.07

Donde:

- r = número de relaciones de cointegración
- $test$ = valor del estadístico de prueba
- 10pct, 5pct, 1pct = valores críticos a diferentes niveles de significancia

Regla de decisión:

- Si $test > \text{valor crítico} \rightarrow \text{Rechazamos } H_0$
- Si $test \leq \text{valor crítico} \rightarrow \text{No rechazamos } H_0$

Cuadro IX
TEST DE COINTEGRACIÓN

Prueba	H_0	H_1	Dec.	Resultado
$r = 0$	No coint.	≥ 1	Rech.	Cointegración
$r \leq 1$	≤ 1	≥ 2	Rech.	≥ 2 vec.
$r \leq 2$	≤ 2	3	No	2 vec.

XII. MODELO DCC-GARCH

Los modelos DCC-GARCH son un tipo de métodos econométricos que se puede usar para medir, modelar y predecir la volatilidad en las series de manera dinámica.

La característica principal es que permite que tanto la volatilidad (varianza condicional) como la correlación entre activos cambien a lo largo del tiempo, capturando así la naturaleza fluctuante de los mercados financieros el modelo está definido por:

XII-A. Media (AR(p) para cada $\beta_{i,t}$):

$$\beta_{i,t} = \mu_i + \sum_{k=1}^p \phi_{ik} \beta_{i,t-k} + \varepsilon_{i,t}, \quad i = 1, 2, 3$$

donde:

- $\beta_{i,t}$: los betas del modelo DNS
- μ_i : constante representa la media de $\beta_{i,t}$
- ϕ_{ik} : coeficientes AR
- p : número de rezagos
- $\varepsilon_{i,t} \sim N(0, h_{i,t})$ residuos

XII-B. Varianzas condicionales univariadas (GARCH(1,1)):

$$h_{i,t} = \omega_i + \alpha_i \varepsilon_{i,t-1}^2 + \beta_i h_{i,t-1}, \quad i = 1, 2, 3$$

XIII. PREDICCIONES DEL MODELO DCC-GARCH

Predicción de la media (AR(p))

Para cada factor i :

$$\hat{\beta}_{i,t+h|t} = \mu_i + \sum_{k=1}^p \phi_{ik} \hat{\beta}_{i,t+h-k|t}$$

donde:

- $\hat{\beta}_{i,t+h|t}$ es la predicción de β_i h pasos adelante, dado la información hasta el tiempo t .
- Para $k > h$, usas los valores observados $\beta_{i,t+k-h}$.
- Para $k \leq h$, usas los valores predichos previamente $\hat{\beta}_{i,t+k|t}$.

Predicción de la varianza condicional (GARCH)

Para la varianza de cada beta:

$$\hat{h}_{i,t+h|t} = \omega_i + \alpha_i \hat{\varepsilon}_{i,t+h-1|t}^2 + \beta_i \hat{h}_{i,t+h-1|t}$$

- Para $h = 1$, $\hat{\varepsilon}_{i,t|t} = \varepsilon_{i,t}$ (último residuo conocido).
- Para $h > 1$, se reemplaza $\hat{\varepsilon}_{i,t+h-1|t}^2$ por su valor esperado, usualmente $\hat{h}_{i,t+h-1|t}$ si asumimos $E[z_{i,t+h}^2] = 1$.

XIV. AJUSTE MODELO DCC-GARCH




Figura 7. Enter Caption




Figura 8.




Figura 9.




Figura 10.

Cuadro X
RESULTADOS DEL TEST ARCH PARA HETEROCEDASTICIDAD

Serie	Test ARCH (p-value y resultado)
Serie 1	p-value: 0.6901627 NO hay heterocedasticidad
Serie 2	p-value: 0.07974864 NO hay heterocedasticidad
Serie 3	p-value: 0.9672551 NO hay heterocedasticidad

Empezaremos prediciendo 14 periodos hacia adelante, en este caso nuestra data esta dividida mensualmente entonces estimaremos las tasas los siguientes 14 meses desde el ultimo mes de nuestra data que es noviembre 2011 que son:

Cuadro XI
RESULTADOS DEL TEST LJUNG-BOX PARA AUTOCORRELACIÓN

Serie	Resultado del Test Ljung-Box
Serie 1	p-value: 0.8284188 No hay evidencia de autocorrelación
Serie 2	p-value: 0.406548 No hay evidencia de autocorrelación
Serie 3	p-value: 0.8787386 No hay evidencia de autocorrelación

Cuadro XII
CUADRO II: VALORES REALES

t	M1	M3	M6	Y2	Y5	Y7	Y10
1	1.7000	1.4000	1.3500	0.8400	1.2200	1.2200	1.6200
2	1.8000	1.6500	1.5000	0.8950	1.2900	1.4700	1.7100
3	1.6500	1.5500	1.5000	1.0300	1.4400	1.6300	1.9000
4	1.5500	1.4700	1.4700	1.2800	1.6000	1.7600	1.9800
5	1.5500	1.4500	1.4000	1.1500	1.4100	1.5600	1.7900
6	1.5000	1.3200	1.3500	0.7700	0.9770	1.0800	1.2800
7	1.3000	1.1000	1.1000	0.9920	1.2300	1.3500	1.6000
8	1.4500	1.1000	1.1000	0.9700	1.0600	1.1600	1.3800
9	1.5000	1.1500	1.1200	0.8540	1.0100	1.1500	1.4100
10	1.1200	1.0000	0.9500	0.6750	0.9680	1.1400	1.4700
11	1.2500	1.1000	1.0300	0.7630	1.0100	1.1900	1.5300
12	1.2300	1.0700	0.9500	0.7140	0.9580	1.1500	1.4700
13	1.0500	0.9800	0.8900	0.7380	0.9680	1.2000	1.5300
14	1.0500	0.9400	0.8800	1.0200	1.3800	1.6200	1.9800

Ahora después de estimar nuestros beta nuestras predicciones serán:

Cuadro XIII
CUADRO II: VALORES ESTIMADOS

t	$\hat{M}1$	$\hat{M}3$	$\hat{M}6$	$\hat{Y}^2$	$\hat{Y}^5$	$\hat{Y}^7$	$\hat{Y}^{10}$
1	1.6732	1.4599	1.2073	0.6930	1.0845	1.3546	1.6107
2	1.5528	1.3468	1.1042	0.6335	1.0651	1.3471	1.6129
3	1.4831	1.2894	1.0621	0.6335	1.0682	1.3448	1.6047
4	1.3528	1.1732	0.9636	0.5908	1.0443	1.3209	1.5793
5	1.2182	1.0545	0.8653	0.5571	1.0352	1.3128	1.5706
6	1.0995	0.9494	0.7775	0.5235	1.0204	1.2981	1.5547
7	0.9734	0.8367	0.6819	0.4826	1.0005	1.2794	1.5356
8	0.8522	0.7281	0.5895	0.4423	0.9815	1.2619	1.5183
9	0.7420	0.6293	0.5052	0.4044	0.9620	1.2436	1.4999
10	0.6375	0.5352	0.4244	0.3666	0.9415	1.2244	1.4808
11	0.5412	0.4483	0.3496	0.3308	0.9216	1.2056	1.4622
12	0.4541	0.3697	0.2818	0.2976	0.9021	1.1870	1.4435
13	0.3746	0.2978	0.2196	0.2664	0.8829	1.1685	1.4248
14	0.3028	0.2327	0.1631	0.2373	0.8642	1.1503	1.4063




Figura 11.

XV. TRABAJO FUTURO

El modelo de Nelson-Siegel dinámico fue el implementado en el trabajo en forma de ecuación, donde los factores de nivel, pendiente, curvatura y λ fueron estimados a partir de mínimos cuadrados. De esta forma se tiene la posibilidad de describir de modo directo y sencillo la dinámica temporal de la estructura de las tasas de interés.

Se ha de proponer una posible línea de investigación futura, que pasaría por replantear el modelo a implementar dentro de un entorno de espacio de estados, y el uso de métodos de estimación para los factores latentes mediante el uso del Filtro de Kalman, y comparar cual nos dara mejores estimaciones.

DISPONIBILIDAD DE DATOS

El conjunto de datos utilizados son series históricas de tipos de interés y rendimientos de bonos suecos recopilados mensualmente desde enero de 1996 hasta noviembre de 2011. pueden encontrarse en el repositorio de GitHub con el nombre `ADVANCED_RESULT_2025-09-15_21_32.xlsx` se utilizara la columna ultimo en este trabajo.

AGRADECIMIENTOS

A todas las personas que confiaron en mi, a toda mi familia y a mi padre Leonel Espinoza y mi madre Brenda Estrada por siempre estar para mi, también a Cristian Espinoza y Elvi Amador por apoyarme en el momento que mas lo necesite y por confiar en mi, a mi gatita Margarita que ya falleció pero en mas de la mitad de la carrera estuvo con migo en todas las noches de desvelo acompañándome siempre, esto no hubiera sido posible sin ellos.

CONCLUSIONES

- El Modelo Nelson-Siegel Dinámico (DNS) es efectivo para estimar la curva de rendimientos sueca
- Ambos modelos ofrecieron pronósticos de rendimientos a 14 meses, mostrando patrones consistentes.
- El modelo DCC-GARCH demostró ser superior al modelo VAR en términos de cumplimiento de los supuestos estadísticos y se refleja en un mejor desempeño predictivo.

REFERENCIAS

- [1] <https://quantdare.com/interest-rates-modeling/>
- [2] http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S0121-47722008000100004#AA1
- [3] <https://repositoriodigital.bcentral.cl/xmlui/bitstream/handle/20.500.12580/3541/BCCh-rec-v14n3dic2011p057-074.pdf?sequence=1&isAllowed=y>
- [4] Diebold, F. X., & Rudebusch, G. D. (2013). Yield Curve Modeling and Forecasting: The Dynamic Nelson-Siegel Approach. Princeton University Press.
- [5] Lütkepohl, H. (2005). New Introduction to Multiple Time Series Analysis. Springer.
- [6] Hamilton, J. D. (1994). Time Series Analysis. Princeton University Press.
- [7] Engle, R. F. (2002). Dynamic Conditional Correlation: A Simple Class of Multivariate GARCH Models. Journal of Business & Economic Statistics, 20(3), 339-350.
- [8] Sosa Castro, M. M., Cabello Rosales, A., & Ortiz Calisto, E. (2020). Construcción de portafolios condicionales vs tradicionales: aplicación al Mercado Integrado Latinoamericano (MILA). Estudios Gerenciales, 36(157), 443-456.

- [9] Hernández-García, R., López-Martínez, P., & Rodríguez-Sánchez, M. (2020). Volatilidad dinámica en el sector bancario en México: evidencia DCC-GARCH vs Cópula-GARCH/Dynamic volatility of bank stock returns in Mexico: DCC-GARCH vs Copula-GARCH evidence. Revista Mexicana de Economía y Finanzas (REMEF): The Mexican Journal of Economics and Finance, 15(4), 123-145.
- [10] GitHub: <https://github.com/abi0498/seminario-de-investigacion>.